

(a) 오프라인 점 평가 (체크포인트마다)

L8-X 보호 분할 7세트

dev

OOD-H

OOD-O

OOD-D

OOD-S

OOD-T

OOD-HL

새 물체 OOD-O58

L8S 보류 검증
(최적 예측 선택)

G 1,577행: 학습에서 뺀 공개 과제·기체 + 가리키기 벤치
MolmoBot Franka = 3인칭 → 보고만, 판정 제외

판정 ni_judge (실행 전 고정)

접근 3D 오차의 중앙값 + 20 mm 초과 실패율
비열등 여유 = 같은 모델 시드 쌍(A/A)의 흔들림
딱 부트스트랩 95 % 구간, 기준 f35_d

(b) 페루프 E-M35CL (보고만)


같은 편을 체크포인트마다 (f35_d → 0.5 → ... → 3)



OOD-O58 + L8S 보류 약 160편 × 4조건
모든 편 영상 저장

판정 규칙 없음
약 15 %p 이상 차이만 읽는다
(새 물체 개선이 페루프에서도 유지되는가)

(c) 결합 평가: 같은 시드의 2×2 (2단계)



연결 손실 = $\min(\text{상한 A}, \text{상한 B}) - \text{결합} \leq 5 \%p$

실패 탓 가르기: 한쪽만 참값으로 바꾼 반사실 재생
→ 상위 / VLA / 연결(인터페이스) 탓, 연결 탓 ≤ 실패의 10 %

H-J: 같은 VLA를 단독(스스로 계획) 대 상위 아래 조이스틱으로
같은 장면에서 비교 → 짐을 덜어 준 쪽이 나아야 채택

참값 = 시물 특권 정보로 계산한 명령·실행